

«بیان خطا»

نظریه یادگیری ماشین

اصیرضناوری

عنوان سوم

۹۹/۱۰/۱۷

①

از) در تابع هزینه داده شده عناصری است رخداده ارن حرف هزینه نمود. هزینه تابع هزینه ماده شد - ملت آن مطلق

قبل شرکتی است. حال تعریف slack را دوست شرکتی کنم رتبه اول ملک مطالعه خواهد شد.

شخص نشد.

$$y_i - \langle w, x_i \rangle - \varepsilon \leq \varepsilon_i$$

$$\langle w, x_i \rangle - y_i - \varepsilon \leq \varepsilon_i^*$$

$$\varepsilon_i, \varepsilon_i^* \geq 0 \quad i = 1, 2, \dots, n$$

حال فرم اصلی را بتوانیم به صورت زیر بنویسیم

$$\min_{w \in \mathbb{R}^m, \varepsilon \in \mathbb{R}^n, \varepsilon^* \in \mathbb{R}^n} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\varepsilon_i + \varepsilon_i^*)$$

در این داده بالاتر را ببردارید و نشان بگیرید که QP می‌شود.

کارانشیز ب شکل زیر خواهد بود

$$L = L(w, \varepsilon, \varepsilon^*, \alpha, \alpha^*, \beta, \beta^*) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\varepsilon_i + \varepsilon_i^*) - \sum_{i=1}^n (\beta_i \varepsilon_i + \beta_i^* \varepsilon_i^*)$$

$$- \sum_{i=1}^n \alpha_i (\beta_i + \varepsilon_i - y_i + \langle w, x_i \rangle) - \sum_{i=1}^n \alpha_i^* (\beta_i^* + \varepsilon_i^* + y_i - \langle w, x_i \rangle)$$

$$\star \rightarrow \alpha_i, \alpha_i^*, \beta_i, \beta_i^* \geq 0, \quad (i=1, \dots, n)$$

$$\min_{w \in \mathcal{E}^*} \max_{\alpha^*, \beta^*} L(w, \varepsilon, \varepsilon^*, \alpha, \alpha^*, \beta, \beta^*) = \max_{\alpha^*, \beta^*} \min_{w \in \mathcal{E}^*} L(w, \varepsilon, \varepsilon^*, \alpha, \alpha^*, \beta, \beta^*)$$

جذب مترادفات (Strong Duality) ، QP مترادفات

حل مشتق فرضی نسبت به $w, \varepsilon_i, \varepsilon_i^*$

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^n (\alpha_i - \alpha_i^*) x_i = 0$$

$$\frac{\partial L}{\partial \varepsilon_i} = C - \alpha_i - \beta_i = 0 \quad \left\{ \Rightarrow \beta_i = C - \alpha_i \right\},$$

$$\frac{\partial L}{\partial \varepsilon_i^*} = C - \alpha_i^* - \beta_i^* = 0 \quad \left\{ \Rightarrow \beta_i^* = C - \alpha_i^* \right\}.$$

حال بـ $w, \varepsilon_i, \varepsilon_i^*$ عبارت صریح داریم و

$$L = \frac{1}{2} \|w\|^2 + \left(\sum_{i=1}^n (\varepsilon_i + \varepsilon_i^*) - \sum_{i=1}^n (\beta_i \varepsilon_i + \beta_i^* \varepsilon_i^*) - \sum_{i=1}^n \alpha_i (\varepsilon_i + \varepsilon_i^*) y_i + \langle w, x_i \rangle \right) - \sum_{i=1}^n \alpha_i^* (\varepsilon_i + \varepsilon_i^* + y_i - \langle w, x_i \rangle)$$

$$= \frac{1}{2} \left\| \sum_{i=1}^n (\alpha_i - \alpha_i^*) x_i \right\|^2 + \sum_{i=1}^n \varepsilon_i \underbrace{(C - \beta_i - \alpha_i)}_0 + \sum_{i=1}^n \varepsilon_i^* \underbrace{(C - \beta_i^* - \alpha_i^*)}_0 \in \sum_{i=1}^n (\alpha_i + \alpha_i^*) + \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*)$$

$$+ \sum_{i=1}^n (\alpha_i^* - \alpha_i) \underbrace{\langle w, x_i \rangle}_{(\sum_{j=1}^n (\alpha_j - \alpha_j^*) x_j, x_i)}$$

$$= -\frac{1}{2} \sum_{i,j=1}^n (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) \langle x_i, x_j \rangle - \sum_{i=1}^n (\alpha_i + \alpha_i^*) + \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*)$$

لابد من λ صفر نیز فواید مترادفات

$$\max_{\alpha^*} -\frac{1}{2} \sum_{i,j=1}^n (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) \langle x_i, x_j \rangle - \sum_{i=1}^n (\alpha_i + \alpha_i^*) + \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*)$$

$$\text{s.t. } \alpha_i, \alpha_i^* \in [0, C]$$

(ب)

پر: نیز اکنون مسند دارم که تصور خلی صند و تغیر دهن

(c)

شروع کردنی که KKT شرط

$$(I) \alpha_i^* (\epsilon + \xi_i - y_i + \langle w_i, x_i \rangle) = 0$$

$$\alpha_i^* (\epsilon + \xi_i^* + y_i - \langle w_i, x_i \rangle) = 0$$

$$\beta_i \xi_i = 0$$

$$\beta_i^* \xi_i^* = 0 \quad \forall i = 1, \dots, n$$

$$(\epsilon + \xi_i - y_i + \langle w_i, x_i \rangle) = 0 \quad \text{با اینجا} \quad \alpha_i^*$$

فی شود. اگر $\xi_i > 0$ باشد باید x_i در مرز را دارد، اگر $\xi_i = 0$ باشد x_i در مرز را ندارد.

نیز خارج از مرز است و α_i^* نیز مرز خواهد بود.

به صورت مثالی می‌دانم که α_i^* است و $\alpha_i^* > 0$ است و $\alpha_i^* < 0$ است و $\alpha_i^* = 0$ است.

نیز x_i را مثالی نمایم که x_i مرز خواهد بود.

$$P(x) = \langle w, x \rangle, \quad w = \sum_{i=1}^n (\alpha_i^* - \alpha_i) x_i \rightarrow P(x) = \sum_{i=1}^n (\alpha_i^* - \alpha_i) \langle x_i, x \rangle$$

$$\text{term} = \sum_{i=1}^n (\alpha_i^* - \alpha_i) k(x_i, x)$$


این عدد از چیزی که

$\alpha \in \mathbb{R}$ تغییر

کلاس  memory hard یعنی SVM یعنی ساده کوئی نیست و $\alpha_i^* > 0$ است.

دانش باقی کردن از حد این کاری یعنی SVM پذیرش نماید. پس یکی از مدل های باقی بود

جسے sparse ہوں گے تو support vector ہی بیشتری داشتہ ہیں۔ لکھ برسے اور باعث ہی شود تا بجای ب




بجای

تغیر C

ایز تغیر سان دھنہ ایسے کہ وہ خود جطاوی C پر مبنی Penalize ہے لیکن یہ سی نہار بھائی

صوبہ دیں باتیں بالے جطاوی کو اور فیٹنیں بخود ملائیں ان بعنی نادیدھن اور وہ آندرست



نہیں اسے.

$$|H| = 1000$$

$$\epsilon = 0.05$$

$$\delta = 0.05$$

طبق قفسی Hausster P&R Board مذکور: $m \geq \frac{1}{\epsilon} (\ln |H| + \ln(1/\delta))$ وجود دارد تغیر کر لاحر فریم Consistent

لکھ برسے اور ملے 8-15-15

$$m \geq \frac{1}{\epsilon} (\ln |H| + \ln(1/\delta))$$

$$\Rightarrow m \geq \frac{1}{0.05} \left(\ln(1000) + \ln\left(\frac{1}{0.05}\right) \right) \approx 197,049$$

پر حاصل: 199 غرض نیازدار ہے

ائبات این قفسه در اینجا ملت سلیمانی موجود است. به این ترتیب از اینجا فرموده شد.

* فرض کنید در فضای $H \in K$ داریم $\|H\| \leq 1$

$$\Rightarrow P(h_i(h_i) \in S) \leq 1 - \epsilon \rightarrow P(h_i \text{ is consistent on } m \text{ data}) \leq (1 - \epsilon)^m$$

$$\Rightarrow P(\text{این دوئری را داشته باشند} \mid h_i \text{ مطابق با } h_i \text{ این دوئری را داشته باشند}) \leq (1 - \epsilon)^m \leq \|H\| (1 - \epsilon)^m \leq 1 + 1 \cdot e^{-\epsilon m} \leq \delta$$

$$\Rightarrow \ln(1/\delta) - \epsilon m \leq \ln \delta \rightarrow m \geq \frac{1}{\epsilon} (\ln(1/\delta) + \ln(\frac{1}{\delta})) \quad \square$$

(۲)

(۳)

$$z = wx + b$$


$$y = \sigma(z)$$

$$L = \frac{1}{r} (y - t)^r$$

$$R = \frac{1}{r} w^r$$

$$L_{\text{reg}} = L + \lambda R$$

درست جایی:



$$\frac{\partial L}{\partial z} = 1, \quad \frac{\partial L}{\partial R} = 1$$

$$\frac{\partial L}{\partial y} = y - t, \quad \frac{\partial L}{\partial t} = -y$$

$$\frac{\partial y}{\partial z} = \sigma'(z) = \sigma(z)(1 - \sigma(z))$$

$$\frac{\partial R}{\partial w} = w, \quad \frac{\partial^2}{\partial w^2} = P_x, \quad \frac{\partial^2}{\partial x^2} = w, \quad \frac{\partial^2}{\partial b^2} = 1$$

$$\frac{\partial L}{\partial b} = 1 \cdot (y - t) \cdot \sigma'(z) \cdot (1 - \sigma(z)) \cdot 1 = (y - t) \sigma(z) (1 - \sigma(z)) = (\sigma(wx + b) - t) \sigma(wx + b) (1 - \sigma(wx + b))$$

$$\frac{\partial L}{\partial w} = dw + 1 \times (y - t) \times \sigma(z) (1 - \sigma(z)) \times x$$


$$= dw + (\sigma(wx + b) - t) \sigma(wx + b) (1 - \sigma(wx + b)) \times x$$

حل پارامتری جنگل (جبل) ممکن است باشد. حال در واقعه‌ی تراش به کل زیرا اینکه روزه را در

$$w = v - \alpha \frac{\partial \log p}{\partial w}$$

$$b = b - \alpha \frac{\partial \log p}{\partial b}$$

برای کرافت محاسبه بصری دو قسم تر داریم:



اگر مقدار دلخواه نندم نباشد، تغییر بین نوردهای بیرونی آید و نوردهای از حس ابتدا با هم تغییر

خواهند داشت. این عدم تغییر باشکوه شود - بست اسکریپت فیلم مختلف نیزند. برای کم اسید

مقدار دلخواه اولیه - شکل شماره ۲ است. (در این حالت در دلخواه مقداری زیاد نوردهای بی خصیت شده و تغییر نیز دیده شد)

اگر مقدار دلخواه از ابتدا بزرگ باشد، ممکن است تراویث هایی بروز شوند - آنها در back prop خیلی

زیاد شوند و شاهد تغییرات زیاد و ناچاری خواهیم بود و این در درجه converge نباشیم. در واقعه تغییر

خواهانه train بجذب و تابع خوب را باشند optimizor خود.

۲۸

۲ مقدار دلخواه مقدار بلوی در عرض

DATE / / SUBJECT:

$$w = 0.05$$

$$b = 0.1$$

$$x = 0$$

$$t = 0$$

$$\frac{\partial \log}{\partial w} = \frac{\partial \log}{\partial w} = (\delta(0.05) - 1)(\delta(0.05))(1 - \delta(0.05)) \times 0.05 + 0.05 \times 1 \\ = 0.05 \lambda \times (-1, 1)$$

$$\rightarrow \frac{\partial \log}{\partial b} = (\delta(0.05) - 1)(\delta(0.05))(1 - \delta(0.05)) = -0.1^T \lambda$$

$$\Leftrightarrow w = 0.05 - 0.1(-0.1\lambda - 1, 1)$$

$$b = 0.1 - 0.1(-0.1^T \lambda) = \underline{0.1^T \lambda}$$

\Rightarrow

$$w = 0.1$$

$$b = 0.1$$

$$x = 1$$

$$t = 1$$

$$\rightarrow \frac{\partial \log}{\partial w} = 0.1 - 0.1^T \lambda = 0.1\lambda - 0.1^T \lambda$$

$$\rightarrow \frac{\partial \log}{\partial b} = -0.1^T \lambda$$

$$\rightarrow w = 0.1 - 0.1(0.1\lambda - 0.1^T \lambda)$$

$$b = 0.1 - 0.1(-0.1^T \lambda) = \underline{0.1^T \lambda}$$