

در بنام خدا

یادگیری ماشین

اصغر رضا زوری

99151517

تمرین پنجم

1

1

بازل SVD مقدار $v = \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}^T$ بدست می آید. البته به طریقی واضح نیز می توان به SVD رسید

نیت و با توجه به نقاط، می توانه این دو را حذف است. $\begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \end{bmatrix}^T$ نیز بدست است.

$$\left. \begin{aligned} z_1 &= [1, -1] \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = -\sqrt{2} \\ z_2 &= [0, 0] \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = 0 \\ z_3 &= [1, 1] \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = \sqrt{2} \end{aligned} \right\} \Rightarrow \text{sample mean} = 0, \text{ variance} = \frac{1}{n} \sum_{i=1}^3 (z_i - 0)^2$$


$$= \frac{1}{3} (2 + 2) = \frac{4}{3}$$

$$\frac{1}{3-1} (2+2) = 2 \quad \leftarrow \text{unbiased estimation} *$$


$$\left. \begin{aligned} \hat{x}_1 &= z_1 \cdot v = -\sqrt{2} \cdot \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = [-1, -1] \\ \hat{x}_2 &= z_2 \cdot v = 0 \\ \hat{x}_3 &= z_3 \cdot v = \sqrt{2} \cdot \begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix} = [1, 1] \end{aligned} \right\} \begin{aligned} \hat{x}_1 &= x_1, \hat{x}_2 = x_2 \\ \hat{x}_3 &= x_3 \end{aligned} \rightarrow \text{reconstruction error} = 0$$

(۲)

1. a Best PCA component (این)



2. First LDA component (ب)



دایره = +

مربع دایره = -

* تصویرها یکی هستند اما معنی دارند منظور حاصل را به سامان

(۳)

این

از مطالب تدریس شده در کلاس می دانیم که با هر تغییر k و n ~~decreasing~~ ~~maximizing~~ k و n ~~decreasing~~ ~~maximizing~~

است. این به این معناست که ما نمی توانیم که این است برای k را ۲ بار مشاهده کنیم. از اینجا به

n^2 entry دارد (۰ یا ۱)، تعداد متغیری از مقادیر ممکن دارد. از این نتیجه می شود

که k Memo می باید در حافظیت به پایا برسد.

$$\sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} w_j(x) + n B(x) = \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} \|x_i - \mu_j\|^2 + \gamma_{ij} \|\mu_j - \hat{x}\|^2$$

$$= \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} (\|x_i - \mu_j\|^2 + \|\mu_j - \hat{x}\|^2)$$

$$= \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} (x_i^2 + \hat{x}^2 - 2x_i \hat{x} + 2x_i \mu_j + \mu_j^2 - 2x_i \mu_j - 2\hat{x} \mu_j)$$

$$= \sum_{j=1}^k \left(\sum_{i=1}^n \gamma_{ij} (\|x_i - \hat{x}\|^2) \right) + K = n \sum_{i=1}^n (\|x_i - \hat{x}\|^2) + K$$

$$= n^2 T(X) + K$$

$$\Rightarrow \sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} W_j(X) + nB(X) = n^2 T(X) + K$$

دقت کنید $\sum_{j=1}^k \sum_{i=1}^n \gamma_{ij} W_j(X)$ همانند $\sum_{j=1}^k W_j(X)$ است بنابراین در \min ، K \min می شود

می شود. از آنجایی که $n^2 T(X)$ یک ثابت و constant است، نتیجه می شود $nB(X)$ به طریقی

تقریبی \max می شود.

(ب)

با یک استدلال استوار ساده و نشان می دهیم. فرض کنید k مراکز از k غیر فاضلی

باشد. حل فضا کننده یک cluster دیگر به عنوان location دلفه اول می بینیم. از آنجایی که این

آپدیت k مراکز k مراکز کانونی می شود، می دانیم که در نقطه \min برای k مراکز

می بینیم. اگر نشان دهیم که k مراکز غیر فاضلی، آنگاه k مراکز را تشکیل می دهد.

توجه داشته باشید حداقل برای k مراکز فاضلی، k مراکز فاضلی را می توانیم پیدا کنیم.

این بدان معناست که k مراکز فاضلی را می توانیم پیدا کنیم.

اگر بخواهیم k مراکز را انتخاب کنیم که با حداقل k مراکز فاضلی، k مراکز فاضلی را می توانیم پیدا کنیم.

که برابر می شود.

از انجایی که ما می‌خواهیم ضریب اولی را در نظر بگیریم، می‌توانیم به سادگی $\arg \max$ را پیدا کنیم و انتخاب می‌کنیم.

(۴)

از (۳)

$$p(x, z; \theta) = \left(n p_r (1 - p_r) \right)^{z_i} \left((1 - n) p_b^x (1 - p_b)^{1-x} \right)^{1-z_i}$$

$$\ln L_c(\theta) = \sum_{i=1}^m (z_i [\ln(n) + x_i \ln(p_r) + (1-x_i) \ln(1-p_r)] + (1-z_i) [\ln(1-n) + x_i \ln(p_b) + (1-x_i) \ln(1-p_b)])$$

$$0 = \frac{\partial \ln L_c(\theta)}{\partial p_b} = \sum_{i=1}^m (1-z_i) \left(\frac{x_i}{p_b} - \frac{1-x_i}{1-p_b} \right)$$

$$\Rightarrow \hat{p}_b = \frac{\sum_{i=1}^m ((1-z_i) x_i)}{\sum_{i=1}^m (1-z_i)}$$

$$0 = \frac{\partial \ln L_c(\theta)}{\partial n} = \sum_{i=1}^m \left(\frac{z_i}{n} - \frac{1-z_i}{1-n} \right)$$

$$\Rightarrow \hat{n} = \frac{\sum_{i=1}^m z_i}{m}$$

$$0 = \frac{\partial \ln L_c(\theta)}{\partial p_r} = \sum_{i=1}^m z_i \left(\frac{x_i}{\hat{p}_r} - \frac{1-x_i}{1-\hat{p}_r} \right) \Rightarrow \hat{p}_r = \frac{\sum_{i=1}^m (z_i x_i)}{\sum_{i=1}^m z_i}$$

$$P(z_i=1 | x_i=x_i; \theta) = \frac{P(x_i=x_i | z_i=1, \theta) P(z_i=1 | \theta)}{P(x_i=x_i | \theta)}$$

$$= \frac{n p_r^{x_i} (1-p_r)^{1-x_i}}{n p_r^{x_i} (1-p_r)^{1-x_i} + (1-n) p_b^{x_i} (1-p_b)^{1-x_i}}$$

عادل با سنج جتنی + خواص بود. تنها z_i را با x_i^t جایگزین کنیم:

$$\hat{n}^{t+1} = \frac{\sum_{i=1}^m x_i^t}{m}$$

$$\hat{p}_r^{t+1} = \frac{\sum_{i=1}^m (x_i^t x_i)}{\sum_{i=1}^m x_i^t}$$

$$\hat{p}_b^{t+1} = \frac{\sum_{i=1}^m ((1-x_i^t) x_i)}{\sum_{i=1}^m (1-x_i^t)}$$